

Chapitre 2Estimation ponctuelle1 - Généralités:

On cherche à déduire à partir des caractéristiques d'un échantillon, les caractéristiques de la population dont il est issu. L'estimation ponctuelle consiste à donner des valeurs approximatives aux paramètres d'une population à l'aide d'un échantillon de n observations. On peut se tromper sur les valeurs exactes à estimer mais on donne les meilleures valeurs possibles que l'on peut supposer.

Soit $(E, \mathcal{E}, \{P_\theta, \theta \in \Theta \subseteq \mathbb{R}^k\})$ un modèle induit par \mathbf{X} et $\tilde{\mathbf{X}} = (\tilde{x}_1, \dots, \tilde{x}_n)$ un échantillon de \mathbf{X} .

Définition:

On appelle estimateur de $g(\theta)$ (mesurable) toute statistique $T_n = T(\tilde{\mathbf{X}})$ défini de $E^n \rightarrow g(\theta)$. Une réalisation de T_n est appelée estimation et elle est notée par $t_n = T(\tilde{\mathbf{x}})$: c'est à dire la valeur prise par la statistique T_n au point $\tilde{\mathbf{x}} = (x_1, \dots, x_n)$.

2 - Méthodes d'estimation2-1 - Méthode des moments (MM)

Soit $r \in \mathbb{N}^*$; notons par :

$$\mu_r(\theta) = \mathbb{E}(X^r)$$

moment non centré théorique d'ordre r

$$m_r = \frac{1}{n} \sum_{i=1}^n X_i^r$$

moment non centré empirique d'ordre r

Définition :

Si $H \theta \in \Theta$, $\mu_k(\theta) < +\infty$ et que

$$\begin{cases} \mu_1(\theta) = m_1 \\ \mu_2(\theta) = m_2 \\ \vdots \\ \mu_k(\theta) = m_k \end{cases}$$

admet une unique solution,
celle-ci est appelée l'estimateur
de θ par la MIM.

Exemple :

① Modèle de Poisson } $\mathcal{P}(\lambda), \lambda > 0$

$$\text{Résoudre } \mathbb{E}(X) = \bar{X} \Rightarrow \lambda = \bar{X}$$

$\Rightarrow \bar{X}$ est l'estimateur de λ par la MIM.

② Modèle Uniforme } $U(I_0, \theta)$, $\theta > 0$

$$\text{On a: } \mathbb{E}(X) = \bar{X} \Rightarrow \frac{\theta}{2} = \bar{X} \Rightarrow \theta = 2\bar{X}$$

Donc $\hat{\theta} = 2\bar{X}$ est l'estimateur de θ par la MIM.

③ Modèle gamma $\{ \gamma(\lambda, k) / k > 0, \lambda > 0 \}$

Résolvons $\begin{cases} E(X) = \bar{x} \end{cases}$

$$\begin{cases} E(X) = \bar{x} \\ E(X^2) = \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 \end{cases}$$

$$\Rightarrow \begin{cases} E(X) = \bar{x} = \frac{k}{\lambda} \end{cases}$$

$$\Rightarrow E(X^2) = \frac{k}{\lambda^2} + \frac{k^2}{\lambda^2} \quad (E(X^2) = \text{Var}(X) + [E(X)]^2)$$

$$\begin{cases} \bar{x} = \frac{k}{\lambda} \\ \bar{x}^2 = \frac{k}{\lambda^2} + \frac{k^2}{\lambda^2} \end{cases}$$

$$\begin{cases} k = \lambda \bar{x} \\ \bar{x}^2 = \frac{\lambda}{\lambda} + (\bar{x})^2 \end{cases}$$

$$\Rightarrow \begin{cases} k = \lambda \bar{x} \\ \bar{x}^2 = \bar{x}^2 - \bar{x}^2 = s^2 \end{cases} \Rightarrow \begin{cases} k = \lambda \bar{x} \\ \lambda = \frac{\bar{x}}{s^2} \end{cases}$$

$$\begin{cases} k = \frac{(\bar{x})^2}{s^2} \\ \lambda = \frac{\bar{x}}{s^2} \end{cases}$$

$$\Rightarrow \hat{\theta} = (\hat{k}, \hat{\lambda}) = \left(\frac{\bar{x}}{s^2}, \frac{\bar{x}^2}{s^2} \right)$$

$$\Rightarrow \hat{\theta} = (\hat{k}, \hat{\lambda}) = \left(\frac{\bar{x}^2}{s^2}, \frac{\bar{x}}{s^2} \right)$$

Attention : $\bar{x}^2 = (\bar{x})^2 \neq \bar{x^2} = \frac{1}{n} \sum x_i^2$

$\hat{\theta}$ est l'estimateur de θ par la MM.

2-2 - Méthode du maximum de vraisemblance (MMV)

Définition :

On appelle estimateur du paramètre θ obtenue par la MMV la fonction $\hat{\theta}$ statistique qui maximise la fonction de vraisemblance c'est à dire

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\tilde{x}; \theta)$$

On utilise souvent $\hat{\theta}$ qui maximise la fonction $\log[L(\tilde{x}, \theta)]$ appelée log-vraisemblance.

Exemple :

Considérons le modèle uniforme $(U[0, \theta], \theta > 0)$

$$L(\tilde{x}, \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \frac{1}{\theta}, x_i \in [0, \theta]$$

$$\approx L(\tilde{x}, \theta) = \frac{1}{\theta^n}; x_i \in [0, \theta]$$

Comme la vraisemblance est une fonction décroissante en θ et que toutes les v.a X_i sont dans $[0, \theta]$ alors la valeur qui maximise la vraisemblance est

$$\hat{\theta} = \max_{i=1 \dots n} (x_i)$$

Propriété

Si le support de la loi de X ne dépend pas de θ et

que le score est dérivable par rapport à θ alors l'estimateur $\hat{\theta}$ de θ obtenu par la MIMN est solution du système suivant :

$$\begin{cases} S(\tilde{x}; \theta) = 0 \\ \frac{\partial}{\partial \theta} S(\tilde{x}; \theta) / \hat{\theta} < 0 \end{cases}$$

Exemple:

$$x \sim \mathcal{E}(1/\theta)$$

$$\Rightarrow f(x; \theta) = \frac{1}{\theta} e^{-\frac{1}{\theta} x}, x \geq 0 \text{ (ne dépend pas de } \theta \text{)}$$

$$* L(\tilde{x}, \theta) = \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum x_i}$$

$$\Rightarrow \log[L(\tilde{x}, \theta)] = -n \log(\theta) - \frac{1}{\theta} \sum_{i=1}^n x_i$$

$$* S(\tilde{x}, \theta) = \frac{\partial}{\partial \theta} \log [L(\tilde{x}, \theta)] = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i$$

$$S(\tilde{x}, \theta) = 0 \Leftrightarrow -n + \frac{1}{\theta} \sum_{i=1}^n x_i = 0$$

$$\Leftrightarrow \hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i$$

Donc $\hat{\theta} = \bar{x}$ est candidat.

* Vérifions la seconde condition

$$\frac{\partial}{\partial \theta} S(\tilde{x}, \theta) = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n x_i$$

$$\frac{\partial}{\partial \theta} S(\tilde{x}, \theta) / \hat{\theta} = \frac{n}{\hat{\theta}^2} - \frac{2}{\hat{\theta}^3} \sum x_i = \frac{n}{\hat{\theta}^2} \frac{2n\hat{\theta}}{\hat{\theta}^3}$$

$$\Rightarrow \frac{\partial}{\partial \theta} S(\tilde{x}, \theta) / \hat{\theta} = \frac{n}{\hat{\theta}^2} - \frac{2n}{\hat{\theta}^3} = - \frac{n}{\hat{\theta}^2} < 0$$

D'où $\hat{\theta} = \bar{x}$ est l'EMN

Propriété [d'invariance du IMVS]

Soit $\hat{\theta}$ l'EMN de θ . Soit g une fonction mesurable de $\theta \rightarrow g(\theta) = \hat{\theta}'$, alors l'EMN de $g(\theta)$ est $g(\hat{\theta})$, $g(\theta) \in \Theta^Y$ est donnée par $g(\hat{\theta}) = \hat{g}(\hat{\theta})$

On appelle cette propriété aussi lemme de Zehna.

3 - Qualité d'un estimateur:

3-1 - Biais:

Soit T_n estimateur $g(\theta)$. On appelle biais de l'estimateur

$$b(T_n; g(\theta)) = E(T_n) - g(\theta)$$

* Si $b(T_n; g(\theta)) = 0$ alors on dit l'estimateur est sans biais sinon elle est dite biaisé.

* Si $b(T_n; g(\theta)) \xrightarrow{n \rightarrow +\infty} 0$ alors l'estimateur

est asymptotiquement sans biais.

Exemple:

- * La moyenne empirique \bar{X} est un estimateur sans biais de la moyenne théorique μ .
- * La variance empirique S^2 est un estimateur biaisé de la variance théorique mais asymptotiquement sans biais.

Remarque:

Le biais mesure l'erreur d'estimation lorsqu'il est négatif, l'estimateur sous-estime le paramètre. Lorsqu'il est positif, on fait une sur-estimation.

3-2-Convergence

Définition

L'estimateur T_n de $g(\theta)$ est dit convergent si T_n converge en probabilité vers $g(\theta)$ c'est à dire

$$\lim_{n \rightarrow +\infty} P(|T_n - g(\theta)| \geq \epsilon) = 0$$

Remarque: [condition suffisante]

Si la variance d'un estimateur asymptotiquement sans biais tend vers 0 alors l'estimateur est consistant.

$$P(|\bar{T}_{in} - g(\theta)| \geq \varepsilon) \leq \frac{E[(\bar{T}_{in} - g(\theta))^2]}{\varepsilon^2}$$

$$\Rightarrow P(|\bar{T}_{in} - g(\theta)| \geq \varepsilon) \leq \frac{\text{Var}(\bar{T}_{in}) + b^2(\bar{T}_{in}; g(\theta))}{\varepsilon^2}$$

3-3- Risque quadratique moyen

Définition:

Le risque quadratique moyen ou "Mean square Error" "MSE" mesure la précision de l'estimation. Elle est dé-

-finie par :

$$R(\bar{T}_{in}; g(\theta)) = E[(\bar{T}_{in} - g(\theta))^2]$$

Remarque:

$$R(\bar{T}_{in}; g(\theta)) = \text{Var}(\bar{T}_{in}) + b^2(\bar{T}_{in}; g(\theta))$$

Définition

Soient \bar{T}_{in} et \bar{T}'_{in} deux estimateurs de $g(\theta)$. On dit que \bar{T}_{in} est préférable à \bar{T}'_{in} si :

$$R(\bar{T}_{in}; g(\theta)) \leq R(\bar{T}'_{in}; g(\theta))$$

4- Estimateur optimal

Définition:

On dit que l'estimateur \bar{T}_{in} de $g(\theta)$ est optimal s'il est préférable à tous les estimateurs de $g(\theta)$.

4-1 - Information de Fisher :

Définition:

Soit $\{P_\theta ; \theta \in \Theta\}$ où Θ est un ouvert un modèle paramétrique. Il est dit régulier s'il vérifie les conditions suivantes :

(H₁) le support des lois est indépendant de θ

$$P_\theta \# (\Delta = \{x \in E \mid f_\theta(x) > 0\})$$

(H₂) $\forall (x; \theta) \in E \times \Theta$, $\frac{\partial}{\partial \theta} f(x; \theta)$ et $\frac{\partial^2}{\partial \theta^2} f(x; \theta)$ existent.

(H₃) $\forall A \in \mathcal{E}$, on a :

$$\frac{\partial}{\partial \theta} \int_A f(x; \theta) dx = \int_A \frac{\partial}{\partial \theta} f(x; \theta) dx < +\infty$$

$$\frac{\partial^2}{\partial \theta^2} \int_A f(x; \theta) dx = \int_A \frac{\partial^2}{\partial \theta^2} f(x; \theta) dx < +\infty$$

Définition:

On appelle information de fisher $I_X(\theta)$ apportée par la variable aléatoire X sur le paramètre θ , la variance de $S(X; \theta)$ (si elle existe). On a :

$$I_X(\theta) = I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log [f(x; \theta)] \right)^2 \right]$$

Exemple:

Soit $X \sim \mathcal{E}(\theta)$; donc $f(x; \theta) = \theta e^{-\theta x}$, $x \geq 0$

$$* \log [f(x; \theta)] = \log(\theta) - \theta x$$

$$* \frac{\partial}{\partial \theta} \log [f(x; \theta)] = \frac{1}{\theta} - x$$

$$* \left(\frac{\partial}{\partial \theta} \log [f(x; \theta)] \right)^2 = \left(\frac{1}{\theta} - x \right)^2 = \frac{1}{\theta^2} - \frac{2}{\theta} x + x^2$$

$$* I_x(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log [f(x; \theta)] \right)^2 \right] = E \left(\frac{1}{\theta^2} - \frac{2}{\theta} x + x^2 \right)$$

$$= \frac{1}{\theta^2} + E(x^2) - \frac{2}{\theta} E(x) = \frac{1}{\theta^2} + \text{Var}(x) + E(x^2) \\ - \frac{2}{\theta} E(x)$$

$$I_x(\theta) = \frac{1}{\theta^2} + \frac{1}{\theta^2} + \frac{1}{\theta^2} - \frac{2}{\theta} \times \frac{1}{\theta} = \frac{1}{\theta^2}$$

$$\Rightarrow \boxed{I_x(\theta) = \frac{1}{\theta^2}}$$

Théorème:

Sous les conditions de régularité, l'information de Fisher rapportée par X sur le paramètre θ est donnée par :

$$I_x(\theta) = -E \left[\frac{\partial}{\partial \theta} S(x; \theta) \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log [f(x; \theta)] \right]$$

$$\mathbb{I}_x(\theta) = -\mathbb{E}\left[\frac{\partial}{\partial \theta} S(x; \theta)\right] = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \log[f(x; \theta)]\right]$$

Preuve:

$$\text{On a: } S(x; \theta) = \frac{\partial}{\partial \theta} \log[f(x; \theta)] = \frac{f'(x; \theta)}{f(x; \theta)}$$

$$\frac{\partial}{\partial \theta} S(x; \theta) = \frac{f''(x; \theta) f(x; \theta) - [f'(x; \theta)]^2}{[f(x; \theta)]^2}$$

$$= \frac{f''(x; \theta)}{f(x; \theta)} - \left[\frac{f'(x; \theta)}{f(x; \theta)} \right]^2$$

$$= \frac{f''(x; \theta)}{f(x; \theta)} - \left(\frac{\partial}{\partial \theta} \log[f(x; \theta)] \right)^2$$

$$\Rightarrow \frac{\partial}{\partial \theta} S(x; \theta) = \frac{f''(x; \theta)}{f(x; \theta)} - [S(x; \theta)]^2$$

$$\Rightarrow \mathbb{E}\left(\frac{\partial}{\partial \theta} S(x; \theta)\right) = \underbrace{\mathbb{E}\left[\frac{f''(x; \theta)}{f(x; \theta)}\right]}_{\Delta} - \mathbb{E}[S(x; \theta)]^2$$

Montrons que $\Delta = 0$

$$\mathbb{E}\left[\frac{f''(x; \theta)}{f(x; \theta)}\right] = \int_E \frac{f''(x; \theta)}{f(x; \theta)} \cdot f(x; \theta) dx$$

$$= \int_E f''(x; \theta) dx = \int_E \frac{\partial^2}{\partial \theta^2} f(x; \theta) dx$$

$$\Rightarrow \mathbb{E}\left[\frac{f''(x; \theta)}{f(x; \theta)}\right] = \frac{\partial^2}{\partial \theta^2} \int_E f(x; \theta) dx \quad (\text{sous H}_3)$$

or par définition $\int_E f(x; \theta) dx = 1$

$$\Rightarrow E\left[\frac{f''(x; \theta)}{f(x; \theta)}\right] = \frac{\partial^2}{\partial \theta^2}(1) = 0$$

$$\Rightarrow \boxed{E([S(x; \theta)]^2) = -E\left(\frac{\partial}{\partial \theta} S(x; \theta)\right)}$$

Exemple:

$$X \sim \mathcal{E}(\theta); f(x; \theta) = \theta e^{-\theta x}, x \geq 0$$

$$I_X(\theta) = -E\left[\frac{\partial^2}{\partial \theta^2} \log[f(x; \theta)]\right] \quad \cancel{\text{for } \frac{\partial^2}{\partial \theta^2}}$$

$$= -E\left(\frac{\partial}{\partial \theta}\left(\frac{1}{\theta} - x\right)\right) = -E\left(-\frac{1}{\theta^2}\right)$$

$$\Rightarrow \boxed{I_X(\theta) = -\left(-\frac{1}{\theta^2}\right) = \frac{1}{\theta^2}}$$

Définition:

On appelle quantité d'information apportée par l'échantillon $\tilde{X} = (X_1, \dots, X_n)$ sur le paramètre θ , la variance (si elle existe) de $S(\tilde{X}; \theta)$.

$$I_{\tilde{X}}(\theta) = I_n(\theta) = E\left[\left(\frac{\partial}{\partial \theta} \log[L(\tilde{X}; \theta)]\right)^2\right]$$

Théorème:

Si le modèle est régulier alors :

$$I_{\tilde{X}}(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log [L(\tilde{x}; \theta)] \right]$$

Exemple:

Modèle exponentielle de paramètre θ de $E(\theta), \theta > 0$.

Si $X \sim E(\theta)$; $f(x; \theta) = \theta e^{-\theta x}, x \geq 0$

Le modèle est régulier alors

$$I_{\tilde{X}}(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log [L(\tilde{x}; \theta)] \right]$$

$$\text{avec } L(\tilde{x}; \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n (\theta e^{-\theta x_i})$$

$$\Rightarrow \log [L(\tilde{x}; \theta)] = \sum_{i=1}^n \log (\theta e^{-\theta x_i}) = \sum_{i=1}^n (\log(\theta) - \theta x_i)$$

$$\Rightarrow \log [L(\tilde{x}; \theta)] = n \log(\theta) - \theta \sum_{i=1}^n x_i$$

$$\Rightarrow \frac{\partial}{\partial \theta} \log [L(\tilde{x}; \theta)] = \frac{n}{\theta} - \sum_{i=1}^n x_i$$

$$\Rightarrow \frac{\partial^2}{\partial \theta^2} \log [L(\tilde{x}; \theta)] = -\frac{n}{\theta^2}$$

$$\Rightarrow I_{\tilde{X}}(\theta) = -E \left(\frac{-n}{\theta^2} \right) = \frac{n}{\theta^2}$$

Remarque:

Si le modèle est régulier alors $I_{\tilde{X}}(\theta) = n I_X(\theta)$.

On parle d'additivité de l'information.

Preuve: (à faire)

Propriétés:

① Pour toute statistique T_n on a: $I_{T_n}(\theta) \leq I_n(\theta)$

avec $I_{T_n}(\theta) = E\left[\left(\frac{\partial}{\partial \theta} \log [f_{T_n}(T_n; \theta)]\right)^2\right]$

② Si le support est indépendant de θ et T_n un estimateur de $g(\theta)$ alors si $I_{T_n}(\theta) = I_n(\theta)$ alors

T_n est une statistique exhaustive.

4-2- Bornes de Cramer-Rao (CR)

ou Frechet-Cramer-Darmois-Rao (FCDIR)

Théorème:

Considérons un modèle régulier et soit $T_n = T(\tilde{x})$ un estimateur sans biais de $g(\theta) \in \mathbb{R}$, $0 < T_n < +\infty$ et

$$\frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} T(\tilde{x}) L(\tilde{x}; \theta) d\tilde{x} = \int_{\mathbb{R}^n} T(\tilde{x}) \frac{\partial}{\partial \theta} L(\tilde{x}; \theta) d\tilde{x} < +\infty$$

alors g est dérivable et nous avons l'inégalité suivante:

$$\text{Var}(T_n) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}$$

Preuve:

$$E(T_n) = \int_{\mathbb{R}^n} T(\tilde{x}) L(\tilde{x}; \theta) d\tilde{x} = g(\theta)$$

$$\Rightarrow g'(\theta) = \int_{\mathbb{E}^n} T(\tilde{x}) \frac{\partial}{\partial \theta} \ln L(\tilde{x}; \theta) d\tilde{x}$$

$$= \int_{\mathbb{E}^n} T(\tilde{x}) \frac{L'(\tilde{x}; \theta)}{L(\tilde{x}; \theta)} \cdot L(\tilde{x}; \theta) d\tilde{x}$$

$$= \int_{\mathbb{E}^n} T(\tilde{x}) \frac{\partial}{\partial \theta} \log [L(\tilde{x}; \theta)] \cdot L(\tilde{x}; \theta) d\tilde{x}$$

$$\Rightarrow g'(\theta) = \int_{\mathbb{E}^n} T(\tilde{x}) \cdot S(\tilde{x}; \theta) \cdot L(\tilde{x}; \theta) d\tilde{x}$$

donc

$$g'(\theta) = \mathbb{E}[T(\tilde{x}) \cdot S(\tilde{x}; \theta)]$$

$$\text{or } \text{cov}[T(\tilde{x}), S(\tilde{x}; \theta)] = \mathbb{E}(T(\tilde{x}) \cdot S(\tilde{x}; \theta)) - \mathbb{E}(T(\tilde{x})) \cdot \mathbb{E}(S(\tilde{x}; \theta))$$

$$\Rightarrow \text{cov}[T(\tilde{x}), S(\tilde{x}; \theta)] = \mathbb{E}[T(\tilde{x}) \cdot S(\tilde{x}; \theta)]$$

$$\Rightarrow \text{cov}[T(\tilde{x}), S(\tilde{x}; \theta)] = g'(\theta)$$

D'après l'inégalité de Cauchy-Schwarz

$$[\text{cov}(T(\tilde{x}); S(\tilde{x}; \theta))]^2 \leq \text{Var}(T_n) \cdot \text{Var}[S(\tilde{x}; \theta)]$$

$$\Rightarrow [g'(\theta)]^2 \leq \text{Var}(T_n) \cdot I_n(\theta)$$

$$\Rightarrow \text{Var}(T_n) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}$$

Définition :

$$B_{\text{inf}}(\theta) = \frac{[g'(\theta)]^2}{I_n(\theta)}$$

est appelé borne de Cramer - Rao.

Un estimateur atteignant cette borne est dit efficace.

Autrement dit, on ne peut pas trouver un autre estimateur sans biais de variance faible. Un estimateur efficace est le meilleur estimateur.

Exemple :

Soit $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{E}(\lambda/\theta)$

* Déterminer l'EIMN de θ .

* Etudier : biais, consistance, efficacité de $\hat{\theta}$

Solution :

* Déterminons l'EIMN de θ :

$$L(\tilde{x}; \theta) = \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum x_i} \Rightarrow \log [L(\tilde{x}; \theta)] = -n \log(\theta) - \frac{1}{\theta} \sum x_i$$

$$\frac{\partial}{\partial \theta} \log [L(\tilde{x}; \theta)] = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum x_i = 0 \Rightarrow \theta = \bar{x}$$

$\Rightarrow \hat{\theta} = \bar{x}$ est candidat.

$$\frac{\partial^2}{\partial \theta^2} \log [L(\tilde{x}; \theta)] = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum x_i$$

$$\Rightarrow \frac{\partial^2}{\partial \theta^2} \log [L(\tilde{x}; \theta)] / \hat{\theta} = -\frac{n}{\hat{\theta}^2} < 0$$

$\Rightarrow \hat{\theta} = \bar{X}$ est l'EMN de θ

* Etude des propriétés de $\hat{\theta}$

- biais :

$$b(\hat{\theta}; \theta) = E(\hat{\theta}) - \theta = E(\bar{X}) - \theta = E(X) - \theta$$

$$\Rightarrow b(\hat{\theta}; \theta) = \theta - \theta = 0 \Rightarrow \hat{\theta} \text{ est sans biais}$$

- consistance

$$\text{Var}(\hat{\theta}) = \text{Var}(\bar{X}) = \frac{\text{Var}(X)}{n} = \frac{\theta^2}{n}$$

$$\left\{ \begin{array}{l} b(\hat{\theta}; \theta) = 0 \\ \text{Var}(\hat{\theta}) \xrightarrow[n \rightarrow +\infty]{} 0 \end{array} \right. \Rightarrow \hat{\theta} \text{ est consistant}$$

- efficacité

$$I_n(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log [L(\tilde{x}; \theta)] \right]$$

$$= -E \left[\frac{n}{\theta^2} - \frac{2}{\theta^3} \sum x_i \right]$$

$$= -\frac{n}{\theta^2} + \frac{2}{\theta^3} \sum_{i=1}^n E(x) = -\frac{n}{\theta^2} + \frac{2n\theta}{\theta^3}$$

$$\Rightarrow I_n(\theta) = \frac{n}{\theta^2} \text{ or } B_{inf}(\theta) = \frac{[g'(\theta)]^2}{I_n(\theta)} = \frac{1}{n/\theta^2} = \frac{\theta^2}{n}$$

$$\Rightarrow B_{inf}(\theta) = \text{Var}(\hat{\theta})$$

$\hat{\theta}$ est efficace

$$g(\theta) = \theta \Rightarrow g'(\theta) = 1$$

Exercice: TAF.

x_1, \dots, x_n extraits de X de $f(x; \theta) = \theta x^{-(\theta+1)}$, $x \geq 1$
où $\theta > 0$.

1) Déterminer l'EMV : $\hat{\theta}$ de θ .

2) Déduire un estimateur sans biais de θ et calculer sa variance.

3) $g: J_0; +\infty \rightarrow \mathbb{R}_+$
 $\theta \mapsto g(\theta) = 1/\theta$

Montrer que $T_n = g(\hat{\theta})$ est sans biais et efficace de $g(\theta)$ un estimateur.

Solution:

① Déterminons l'EMV : $\hat{\theta}$ de θ :

$$\text{On a: } L(\tilde{x}; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

$$\begin{aligned} \Rightarrow \log [L(\tilde{x}; \theta)] &= \sum_{i=1}^n \log [f(x_i; \theta)] \\ &= \sum_{i=1}^n \log (\theta \cdot x_i^{-(\theta+1)}) \\ &= \sum_{i=1}^n \log (\theta) - (\theta+1) \sum_{i=1}^n \log (x_i) \end{aligned}$$

$$\Rightarrow \log [L(\tilde{x}; \theta)] = n \log (\theta) - (\theta+1) \sum \log (x_i)$$

$$S(\tilde{x}; \theta) = \frac{\partial}{\partial \theta} \log [L(\tilde{x}; \theta)] = \frac{n}{\theta} - \cancel{\sum_{i=1}^n \log (x_i)}$$

$$\Rightarrow S(\tilde{x}; \theta) = 1 \quad \theta = n / \sum \log (x_i)$$

$$\Rightarrow \hat{\theta} = \frac{1}{\frac{1}{n} \sum \log(x_i)} \text{ est candidat}$$

$$\Rightarrow \frac{\partial}{\partial \theta} S(\tilde{x}; \theta) = -\frac{n}{\theta^2} \Rightarrow \frac{\partial S(\tilde{x}; \theta)}{\partial \theta} \Big|_{\hat{\theta}} = -\frac{n}{\hat{\theta}^2} < 0$$

donc $\hat{\theta}$ est un EMMV de θ .

② En déduisons un estimateur sans biais de θ

a) cherchons la loi de $\log(x_i)$

posons $Y_i = \log(x_i)$

$$\begin{aligned} P(Y_i \leq y) &= P(\log(x_i) \leq y) ; \forall y \geq 0 \\ &= P[x_i \leq e^y] \end{aligned}$$

$$\Rightarrow F_{Y_i}(y) = P(Y_i \leq y) = F_{x_i}(e^y)$$

$$\Rightarrow f_{Y_i}(y) = e^y f_{x_i}(e^y)$$

$$= \theta e^y \cdot e^{-\theta} (\theta + 1)$$

$$f_{Y_i}(y) = \theta e^{-\theta y} ; \forall y \geq 0$$

$\Rightarrow Y_i = \log(x_i) \sim \mathcal{E}(\theta)$.

$$\Rightarrow Y = \frac{1}{n} \sum \log(x_i) = \frac{1}{n} \sum Y_i$$

b) cherchons la loi de $\bar{Y} = \frac{1}{n} \sum \log(x_i)$

$$Y_i \sim \mathcal{E}(\theta) = \gamma(1; \theta)$$

$$\Rightarrow \sum Y_i \sim \gamma(n; \theta)$$

$$\Rightarrow \bar{Y} \sim \mathcal{X}(n; n\theta)$$

$$\therefore f_{\bar{Y}}(y) = \frac{(n\theta)^n}{\Gamma(n)} y^{n-1} e^{-n\theta y}, y > 0$$

$$\therefore E\left(\frac{1}{\bar{Y}}\right) = \int_0^{+\infty} \frac{1}{y} \times \frac{(n\theta)^n}{\Gamma(n)} y^{n-1} e^{-n\theta y} dy$$

$$\therefore E\left(\frac{1}{\bar{Y}}\right) = \int_0^{+\infty} \frac{(n\theta)^n}{\Gamma(n)} y^{n-2} \cdot e^{-n\theta y} dy$$

substitutes $u = n\theta y \Rightarrow y = \frac{u}{n\theta} \Rightarrow dy = \frac{1}{n\theta} du$

$$\therefore y > 0 \Rightarrow u > 0$$

$$\therefore E\left(\frac{1}{\bar{Y}}\right) = \int_0^{+\infty} \frac{(n\theta)^n}{\Gamma(n)} \times \frac{1}{(n\theta)} \times (n\theta)^{-n+2} \cdot u^{n-2} e^{-u} du$$

$$= \int_0^{+\infty} \frac{(n\theta)^{n-1-n+2}}{\Gamma(n)} u^{n-2} e^{-u} du$$

$$= \frac{(n\theta)}{\Gamma(n)} \int_0^{+\infty} u^{(n-1)-1} e^{-u} du$$

$$= \frac{(n\theta)}{\Gamma(n)} \times \Gamma(n-1) = \frac{n\theta}{(n-1)!} (n-2)!$$

$$= n\theta \times \frac{1}{(n-1)} \times \frac{1}{(n-2)!} \times (n-2)!$$

$E\left(\frac{1}{\bar{Y}}\right) = \frac{n}{n-1}\theta$

c) déduisons en un estimateur sans biais de θ .

$$E(\hat{\theta}) = \frac{n}{n-1} \theta \Rightarrow \frac{n-1}{n} E(\hat{\theta}) = \theta$$

$$\Rightarrow E\left(\frac{n-1}{n} \hat{\theta}\right) = \theta$$

d'où $\hat{\theta}' = \frac{n-1}{n} \hat{\theta}$ est un estimateur sans biais de θ .

d) Calculons sa variance

$$\text{Var}(\hat{\theta}') = \text{Var}\left(\frac{n-1}{n} \hat{\theta}\right) = \frac{(n-1)^2}{n^2} \text{Var}(\hat{\theta})$$

$$\text{or } \text{Var}(\hat{\theta}) = E(\hat{\theta}^2) - [E(\hat{\theta})]^2$$

$$\begin{aligned} \text{et } E(\hat{\theta}^2) &= \int_0^{+\infty} \left(\frac{1}{y}\right)^2 \cdot \frac{(n\theta)^n}{\Gamma(n)} y^{n-1} e^{-n\theta y} dy \\ &= \frac{(n\theta)^n}{\Gamma(n)} \int_0^{+\infty} y^{n-3} \cdot e^{-n\theta y} dy \\ &= \frac{(n\theta)^n}{\Gamma(n)} \int_0^{+\infty} \cancel{x} \cdot \frac{\Gamma(n-2)}{(n\theta)^{n-2}} \underbrace{\int_0^{+\infty} \frac{(n\theta)^{n-2}}{\Gamma(n-2)} y^{n-2-1} e^{-n\theta y} dy}_{1} \end{aligned}$$

$$E(\hat{\theta}^2) = \frac{(n\theta)^{n-n+2}}{\Gamma(n)} \times \frac{\Gamma(n-2)}{1}$$

$$\text{or } \Gamma(n) = (n-1)(n-2)\Gamma(n-2)$$

$$\Rightarrow E(\hat{\theta}^2) = \frac{n^2}{(n-1)(n-2)} \theta^2$$

$$\text{Var}(\hat{\theta}) = E(\hat{\theta}^2) - [E(\hat{\theta})]^2$$

$$= \frac{(n\theta)^2}{(n-1)(n-2)} - \frac{(n\theta)^2}{(n-1)^2}$$

$$\text{Var}(\hat{\theta}) = \frac{(n\theta)^2}{n-1} \left(\frac{1}{n-2} - \frac{1}{n-1} \right)$$

$$\Rightarrow \text{Var}(\hat{\theta}') = \frac{(n-1)^2}{n^2} \text{Var}(\hat{\theta})$$

$$= \frac{(n-1)^2}{n^2} \times \frac{n^2\theta^2}{n-1} \left(\frac{1}{n-2} - \frac{1}{n-1} \right)$$

$$= (n-1)\theta^2 \left(\frac{1}{n-2} - \frac{1}{n-1} \right)$$

$$= \theta^2 \left(\frac{n-1}{n-2} - 1 \right) = \theta^2 \left(\frac{n-1-n+2}{n-2} \right)$$

$$\Rightarrow \boxed{\text{Var}(\hat{\theta}') = \frac{1}{n-2}\theta^2}$$

$$\textcircled{3} \quad g : J_{0;+\infty} \rightarrow \mathbb{R}_+^* \\ \theta \longmapsto g(\theta) = \frac{1}{\theta}$$

Montons que $\bar{T}_n = g(\hat{\theta})$ est un estimateur sans biais

et efficace :

$$* b(\bar{T}_n, g(\theta)) = E(\bar{T}_n) - g(\theta) = E(g(\hat{\theta})) - g(\theta)$$

Calculons $E(g(\hat{\theta}))$.

$$\hat{\theta} = \frac{1}{\bar{Y}} \Rightarrow g(\hat{\theta}) = \bar{Y} \quad \cancel{g(\theta) = \frac{1}{\theta}}$$

$$b(\bar{T}_n, g(\theta)) = E(\bar{Y}) - \frac{1}{\theta} \quad \text{or} \quad \bar{Y} \sim \mathcal{X}(n, n\theta)$$

$$\Rightarrow E(\bar{Y}) = \frac{n}{n\theta} = \frac{1}{\theta}$$

$$\text{d'où } b(T_n; g(\theta)) = \frac{1}{\theta} - \frac{1}{\theta} = 0$$

donc T_n est un estimateur sans biais de $g(\theta) = 1/\theta$.

* efficacité

$$\text{Var}(T_n) = \text{Var}(\bar{Y}) = \frac{n}{(n\theta)^2} = \frac{1}{n\theta^2}$$

$$B_{\text{inf}} = \frac{[g'(\theta)]^2}{I_{\tilde{X}}(\theta)} \quad \text{avec } g(\theta) = \frac{1}{\theta} \Rightarrow g'(\theta) = -\frac{1}{\theta^2}$$

$$\text{et } I_{\tilde{X}}(\theta) = -E\left[\frac{\partial}{\partial\theta} S(\tilde{X}; \theta)\right] = \frac{n}{\theta^2}$$

$$\Rightarrow B_{\text{inf}} = \frac{1/\theta^4}{n/\theta^2} = \frac{1}{n\theta^2} = \text{Var}(T_n)$$

$\Rightarrow T_n$ est un estimateur efficace.

Remarque:

$$I_{ij}(\theta) = -E \left[\frac{\partial^2}{\partial \theta_i \partial \theta_j} \log [f(x; \theta)] \right]$$

avec $1 \leq i, j \leq k$

Pour tout modèle régulier.

Exemple:

$$\{ N(\mu, \sigma^2), \theta^t = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^* \}$$

induit par X .

- ① Calculer le vecteur score et vérifier qu'il est centré.
- ② Calculer l'information de Fisher apposée par X sur θ .

Solution:

$$\begin{aligned} \textcircled{1} \quad f(x; \mu, \sigma^2) &= \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2}, x \in \mathbb{R} \\ \Rightarrow f(x; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2}, x \in \mathbb{R} \\ \Rightarrow f(x; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \times \frac{(x-\mu)^2}{\sigma^2}}, x \in \mathbb{R} \end{aligned}$$

$$\log[f(x; \mu, \sigma^2)] = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2} \times \frac{(x-\mu)^2}{\sigma^2}$$

$\forall x \in \mathbb{R}$

2-25

$$\frac{\partial}{\partial \mu} \log[f(x; \mu, \sigma^2)] = \frac{x - \mu}{\sigma^2}$$

$$\frac{\partial}{\partial \sigma^2} \log[f(x; \mu, \sigma^2)] = -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2(\sigma^2)^2}$$

$$\text{or } S(x; \mu, \sigma^2) = \nabla \log[f(x; \mu, \sigma^2)]$$

$$\Rightarrow S(x; \mu, \sigma^2) = \begin{pmatrix} \frac{x - \mu}{\sigma^2} \\ -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2\sigma^4} \end{pmatrix}$$

① ~~Montrons~~ Vérifions qu'il est centré :

$$\begin{aligned} E[S(x; \mu, \sigma^2)] &= \begin{pmatrix} E\left(\frac{x - \mu}{\sigma^2}\right) \\ E\left(-\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2\sigma^4}\right) \end{pmatrix} \\ &= \begin{pmatrix} 0 \\ -\frac{1}{2\sigma^2} + \frac{1}{2\sigma^4} E[(x - \mu)^2] \end{pmatrix} \end{aligned}$$

$$E[S(x; \mu, \sigma^2)] = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \text{ car } \underbrace{E[(x - \mu)^2]}_{\text{Var}(x)} = \sigma^2$$

② L'information de fisher avec $E(X) = \mu$.

• Cherchons I_{11}

$$\left(\frac{\partial}{\partial \mu} \log [f(x; \mu, \sigma^2)] \right)^2 = \left(\frac{(x-\mu)}{\sigma^2} \right)^2$$

$$\Rightarrow I_{11} = E \left[\left(\frac{(x-\mu)}{\sigma^2} \right)^2 \right] = \frac{E[(x-\mu)^2]}{\sigma^4} = \frac{1}{\sigma^2}$$

• Cherchons I_{12}

$$\frac{\partial}{\partial \mu} \log [f(x; \mu, \sigma^2)] \cdot \frac{\partial}{\partial \sigma^2} \log [f(x; \mu, \sigma^2)] = A \text{ (On pose)}$$

$$A = \frac{(x-\mu)}{\sigma^2} \left(-\frac{1}{2\sigma^2} + \frac{(x-\mu)^2}{2\sigma^4} \right)$$

$$A = -\frac{1}{2\sigma^4} (x-\mu) + \frac{1}{2\sigma^6} (x-\mu)^3$$

$$I_{12} = E(A) = -\frac{1}{2\sigma^4} E(x-\mu) + \frac{1}{2\sigma^6} E[(x-\mu)^3] = 0$$

car la loi est symétrique

Le moment centré d'ordre k (impair) est égal à 0.

$$\mu_k = \begin{cases} 0 & \text{si } k \text{ impair} \\ \frac{(2p)!}{(p!) 2^p} \sigma^{2p}, & k = 2p \end{cases}$$

• $I_{12} = I_{21} = 0$

(2-27)

• Cherchons I_{22}

$$\left[\frac{\partial}{\partial \sigma^2} \log f(x; \mu, \sigma^2) \right]^2 = \frac{1}{4\sigma^4} + \frac{(x-\mu)^4}{4\sigma^8} - \frac{(x-\mu)^2}{2\sigma^6}$$

$$\Rightarrow I_{22} = \frac{1}{4\sigma^4} + \frac{N_4}{4\sigma^8} - \frac{\sigma^2}{2\sigma^6}$$

$$N_4 = \frac{(2 \times 2)!}{2^2 2!} \sigma^{2 \times 2} = 3\sigma^4$$

$$\Rightarrow I_{22} = \frac{1}{4\sigma^4} + \frac{3\sigma^4}{4\sigma^8} - \frac{1}{2\sigma^4} = \frac{1}{\sigma^4} \left(\frac{1}{4} + \frac{3}{4} - \frac{1}{2} \right)$$

$$\Rightarrow I_{22} = \frac{1}{2\sigma^4}$$

$$I_x(\theta) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2\sigma^4} \end{pmatrix}$$

Puisque le modèle est régulier on pouvait utiliser la formule suivante : $I_{ij} = -E \left(\frac{\partial^2}{\partial \theta_i \partial \theta_j} \log [f(x; \theta)] \right)$

Remarque :

Si $\tilde{x} = (x_1, \dots, x_n)$ échantillon de x alors on a !

2-28

* Vecteur Score

$$S(\tilde{x}; \theta) = \nabla \log [L(\tilde{x}; \theta)]$$

* L'information de fisher apportée par l'échantillon sur θ :

$$I_n(\theta) = E[(S(\tilde{x}; \theta))(S(\tilde{x}; \theta))^T]$$

$$* I_n(\theta) = n I(\theta) \quad \left[I_{\tilde{x}}(\theta) = n I_{\tilde{x}}(\theta) \right]$$

Théorème:

① $\frac{1}{n} \sum_{i=1}^n S(x_i; \theta) \xrightarrow{\text{PDS}} 0$

(D'après la loi forte des grands nombres)

② Si les conditions de régularité sont satisfaites et l'information de fisher existe, nous avons la convergence, grâce au TCL, suivante

$$\frac{1}{\sqrt{n}} \times S(\tilde{x}; \theta) \xrightarrow{\mathcal{D}} \mathcal{N}_{O_k}(0; I(\theta))$$

Preuve ②

On a:

2-29

$$\text{On a } \frac{\bar{Y} - E(\bar{Y})}{\sqrt{\text{Var}(\bar{Y})}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

grâce à la stabilité de la loi normale

$$\bar{Y} - E(\bar{Y}) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \text{Var}(\bar{Y}))$$

$$\text{Var}(\bar{Y}) = \frac{\sigma^2}{n}; \quad Y \sim \mathcal{N}(\mu, \sigma^2)$$

Par analogie :

$$Y_i = S(X_i, \theta)$$

$$\frac{1}{n} \sum S(X_i, \theta) \xrightarrow{\mathcal{L}} \mathcal{N}_k(0_k; \frac{\text{V}[S(\tilde{X}, \theta)]}{n^2})$$

$$\mathcal{N}_k(0_k; \frac{\mathbb{I}(\theta)}{n})$$

$$\sqrt{n} \times \frac{1}{n} \sum S(X_i, \theta) \longrightarrow \mathcal{N}_k(0_k; \mathbb{I}(\theta))$$

$$\sqrt{n} \times \frac{1}{(\sqrt{n})^2} \sum S(X_i, \theta) \longrightarrow \mathcal{N}_k(0_k; \mathbb{I}(\theta))$$

$$\Rightarrow \frac{1}{\sqrt{n}} \sum S(X_i, \theta) \longrightarrow \mathcal{N}_k(0_k, \mathbb{I}(\theta))$$

2-30

Théorème:

Si $\bar{\theta}_n$ est l'EIMN de $g(\theta)$; $g \in C^1$;

$I(\theta)$ existe alors :

$$\sqrt{n}(\bar{\theta}_n - g(\theta)) \xrightarrow{\mathcal{L}} N(0; \frac{\partial g(\theta)}{\partial \theta} I^{-1}(\theta) \cdot \frac{\partial g(\theta)^T}{\partial \theta})$$

On dit que l'estimateur du IM V est asymptotiquement efficace mais aussi asymptotiquement normal.

$$b_{inf}(\theta) = \frac{[g'(\theta)]^2}{I_n(\theta)}$$

$$b_{inf}(\theta) = \frac{\partial g(\theta)}{\partial \theta} I_n^{-1}(\theta) \cdot \frac{\partial g(\theta)^T}{\partial \theta}$$

Dans le cas multidimensionnel

$$V(\bar{\theta}_n) \geq b_{inf}(\theta)$$